Reconstrucción 3D y estimación métrica por estéreo multivista

Trabajo Práctico II

Agustín Patruno Carranza · **Catalina Hirsch** · **Mathias Kneipp**

13 de octubre de 2026

Resumen

1. Introducción y Marco Teórico

El objetivo de este trabajo es reconstruir la nube de puntos 3D de un objeto a partir de un conjunto de imágenes tomadas desde distintos ángulos con una cámara estéreo, y estimar sus dimensiones reales en milímetros. Se utiliza un sistema estéreo porque permite recuperar la profundidad de los píxeles y porque reduce la búsqueda de correspondencias a una recta (la línea epipolar). El pipeline consta de: calibración del par estéreo (intrínsecos, distorsión y extrínsecos relativos R, t), rectificación de las imágenes para alinear las líneas epipolares, cálculo de disparidad para obtener una nube de puntos local por par, estimación de la pose global de cada cámara para fusionar todas las nubes en un marco común, y finalmente optimización de la nube y medición métrica del objeto.

1.1. Modelo de cámara pinhole y distorsión

El modelo pinhole describe cómo una cámara forma una imagen: todos los rayos de luz pasan por un único punto y se proyectan sobre el plano imagen. En esta proyección de perspectiva se pierde la profundidad, ya que un punto del plano puede provenir de infinitos puntos 3D sobre una recta. La proyección de un punto 3D se expresa como

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K \, [\, R \mid t \,] \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

donde K es la matriz de parámetros intrínsecos (proyecta del sistema de la cámara al plano imagen) y $[R|t]$ son los extrínsecos, que describen la rotación y traslación de la cámara respecto del mundo. La matriz K tiene la forma

$$K = \begin{bmatrix} f_x & s & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}$$

Donde f_x y f_y es la distancia focal en píxeles, c_x y c_y es el punto principal (donde el eje óptico corta el plano imagen) y s (skew) es el sesgo entre los ejes, que se asume nulo.

El modelo pinhole ideal no contempla que las lentes reales deforman la imagen. Esto se corrige con los coeficientes de distorsión: la *radial* (k_1, k_2, k_3) arquea las líneas rectas (efecto barril o cojín), notoria en lentes de cámara web como la de este trabajo, y la *tangencial* (p_1, p_2), por desalineación entre lente y sensor.

Tanto K como los coeficientes de distorsión son desconocidos y propios de cada cámara. Sin ellos no se puede relacionar los píxeles con la geometría real ni obtener medidas en milímetros. Por eso es necesario calibrar: estimarlos a partir de un patrón de geometría conocida. Es el cimiento métrico del pipeline, ya que un error en esta etapa se propaga al resto.

1.2. Calibración estéreo

Se estiman la rotación (R) y traslación (t) relativas entre las dos cámaras (de la derecha respecto de la izquierda). Definen la geometría del par y permiten rectificar y recuperar la profundidad: el módulo de t es la línea base (*baseline* B), que entra en $Z = f\,B/d$.

Para estimarlos se toman pares de imágenes de un patrón (checkerboard/ChArUco) de geometría conocida vistos por ambas cámaras a la vez, se detectan sus esquinas y se resuelve una optimización (`stereoCalibrate`) que halla el R, t consistente con todas las vistas (y afina intrínsecos y distorsión).

La calidad se mide con el error de reproyección: se reproyectan los puntos 3D del patrón al plano imagen con los parámetros estimados y se mide, en píxeles, la distancia a las esquinas detectadas, reportada como raíz cuadrática media (RMS); cuanto más bajo, mejor.

$$e_{\text{RMS}} = \sqrt{\frac{1}{N} \sum_{i=1}^{N} \left\| \mathbf{x}_i - \hat{\mathbf{x}}_i \right\|^2}$$

donde $\mathbf{x}_i$ es la esquina detectada, $\hat{\mathbf{x}}_i$ su reproyección a partir del punto 3D conocido, y N el total de

puntos sobre todas las imágenes.

1.3. Geometría epipolar y rectificación

Dado un punto en la imagen izquierda, su correspondiente en la derecha está obligado a caer sobre una recta, la línea epipolar: el punto 3D está sobre el rayo que sale de la cámara izquierda, y ese rayo se proyecta como una recta en la derecha. Así, la búsqueda de correspondencias pasa de 2D a 1D. Esta restricción la captura la matriz fundamental F (o la esencial E): $\mathbf{x}'^{T} F \mathbf{x} = 0$.

En general esas líneas epipolares están inclinadas y a distintas alturas en cada imagen. La rectificación reproyecta (homografía) ambas imágenes a un par ideal con planos imagen coplanares, de modo que las líneas epipolares queden horizontales y alineadas en la misma fila.

Tras rectificar, el correspondiente de un píxel está en la misma fila de la otra imagen, desplazado solo horizontalmente. Ese desplazamiento es la disparidad, $d = x_{\text{izq}} - x_{\text{der}}$. Así, el cálculo de disparidad se reduce a una búsqueda 1D a lo largo de la fila, mucho más rápida y robusta que buscar sobre rectas oblicuas distintas para cada píxel.

1.4. De disparidad a profundidad

En el par rectificado, la profundidad Z de un punto se relaciona con su disparidad d por triángulos semejantes mediante

$$Z = \frac{f\,B}{d}$$

donde f es la distancia focal en píxeles y B la línea base. La relación es inversa, por lo que un mismo error en d afecta más a los puntos lejanos y el estéreo es más preciso de cerca. Como B proviene de la calibración en milímetros, Z queda en unidades métricas, sin la ambigüedad de escala de la reconstrucción monocular. Con la profundidad de cada píxel, la matriz de reproyección Q retroproyecta cada píxel (u, v) a un punto 3D (X, Y, Z), formando la nube local.

2. Metodología

2.1. Calibración y rectificación

2.2. Disparidad y nube local

2.3. Pose global y transformación

2.4. Fusión y optimización en Open3D

2.5. Medición métrica

3. Resultados y Discusión

3.1. Resultados

3.2. Discusión

Referencias

[1] R. Hartley y A. Zisserman. Multiple View Geometry in Computer Vision. 2.ª ed., Cambridge University Press, 2004.

[2] OpenCV. Camera Calibration and 3D Reconstruction. Documentación oficial.

[3] Q.-Y. Zhou, J. Park y V. Koltun. Open3D: A Modern Library for 3D Data Processing. arXiv:1801.09847, 2018.